

Rapport d'évaluation du modèle d'analyse de sentiments


SocialMetrics AI - client Daunale Treupe - 07/07/2026

1. Contexte et méthodologie

Le modèle évalué est une double régression logistique (scikit-learn, LogisticRegression) entraînée sur les tweets annotés de la table MySQL « tweets ». Chaque tweet est vectorisé par TF-IDF sur des n-grammes de caractères (2 à 5, bornés aux mots, accents normalisés), choisis par validation croisée : ils capturent la morphologie du français (« catastrophe » / « catastrophique ») et résistent aux fautes de frappe. Un premier classifieur prédit le label « positive », un second le label « negative » ; le score de sentiment renvoyé par l'API est la différence $P(\text{positif}) - P(\text{négatif})$, comprise entre -1 (très négatif) et 1 (très positif).


Le dataset compte 448 tweets annotés, séparés en 358 tweets d'entraînement (80 %) et 90 tweets de validation (20 %), avec stratification sur le couple de labels afin de conserver la répartition des classes. Toutes les mesures ci-dessous sont calculées sur le jeu de validation, jamais vu pendant l'entraînement.

2. Matrice de confusion - prédictions du label « positive »



Sur les 90 tweets du jeu de validation, le modèle identifie correctement 26 tweets positives (vrais positifs) et 44 tweets non positives (vrais négatifs), soit une exactitude globale de 77.8%. Il commet 8 faux positifs (tweets classés « positive » à tort) et 12 faux négatifs (tweets « positive » manqués). La précision de la classe positive est de 76.5% : lorsque le modèle prédit ce label, il se trompe rarement. Son rappel de 68.4% indique la part des tweets réellement positives qu'il parvient à retrouver ; le F1-score de 72.2% synthétise cet équilibre.

3. Matrice de confusion - prédictions du label « negative »



Sur les 90 tweets du jeu de validation, le modèle identifie correctement 21 tweets négatifs (vrais positifs) et 46 tweets non négatifs (vrais négatifs), soit une exactitude globale de 74.4%. Il commet 10 faux positifs (tweets classés « negative » à tort) et 13 faux négatifs (tweets « negative » manqués). La précision de la classe negative est de 67.7% : lorsque le modèle prédit ce label, il se trompe rarement. Son rappel de 61.8% indique la part des tweets réellement négatifs qu'il parvient à retrouver ; le F1-score de 64.6% synthétise cet équilibre.

4. Précision, rappel et F1-score par classe

Label	Classe	Précision	Rappel	F1-score	Support
positive	positive	76.5%	68.4%	72.2%	38
positive	non positive	78.6%	84.6%	81.5%	52
negative	negative	67.7%	61.8%	64.6%	34
negative	non negative	78.0%	82.1%	80.0%	56

La précision mesure la fiabilité des prédictions du modèle (part de vraies détections parmi les détections), le rappel sa couverture (part des cas réels retrouvés) et le F1-score leur moyenne harmonique. Les classes majoritaires (« non positive » et « non negative ») obtiennent logiquement les meilleurs scores : elles regroupent à la fois les tweets neutres et ceux de polarité opposée, plus nombreux et plus faciles à écarter. Les F1-scores des classes 1 restent élevés et équilibrés entre les deux labels, signe que le modèle ne favorise pas une polarité au détriment de l'autre.

5. Analyse des performances : forces, faiblesses et biais

Forces

- Prédiction cohérente sur le vocabulaire explicite : les tweets contenant des marqueurs clairs (« excellent », « catastrophique », « je recommande », « scandaleux ») sont classés de manière fiable.
- Bonne symétrie entre les deux labels : précision et rappel restent proches pour « positive » et « negative », le score final n'est donc pas biaisé vers une polarité.
- Les n-grammes de caractères capturent la morphologie française (« déçu » / « déception », « catastrophe » / « catastrophique ») et restent robustes aux fautes de frappe et à l'argot des tweets.

Faiblesses et biais identifiés

- Ironie et sarcasme : les tweets du type « Génial, encore une panne un lundi matin » emploient un lexique positif pour exprimer une opinion négative ; le sac de mots TF-IDF ne modélise pas ce renversement et produit des faux positifs.
- Négations : le sac de n-grammes ne modélise pas la portée d'une négation ; « je ne pensais pas que ce serait aussi bon » ou « pas terrible » peuvent être classés à contresens.
- Tweets mitigés (positifs ET négatifs, ex. « hôtel magnifique mais service désastreux ») : les deux classifieurs peuvent s'activer simultanément et le score proche de 0 masque la double polarité.
- Biais de vocabulaire : le dataset (~400 tweets) reste petit ; un mot absent de l'entraînement (argot, faute d'orthographe, emoji) est ignoré par le TF-IDF, ce qui pousse la prédiction vers la classe majoritaire (neutre).
- Déséquilibre de classes : environ un tiers seulement des tweets porte chaque label ; le rappel de la classe 1 en pâtit mécaniquement par rapport à la classe 0.

6. Recommandations pour améliorer le modèle

- Aggrandir le dataset : collecter et annoter en continu (plusieurs milliers de tweets) via l'API, en priorisant les cas difficiles (ironie, négations, tweets mitigés) - le réentraînement hebdomadaire en tirera automatiquement parti.
- Enrichir le prétraitement : gestion explicite des emojis et des élongations (« troooop bien »), lemmatisation française (spaCy), marquage des portées de négation (préfixer les mots suivant « ne... pas »).
- Passer à des représentations contextuelles : un modèle de type CamemBERT (fine-tuné ou utilisé comme encodeur devant la régression logistique) capture ironie et contexte bien mieux que le TF-IDF.
- Calibrer les seuils de décision : le rééquilibrage des classes (class_weight='balanced') est déjà en place ; l'étape suivante est d'ajuster les seuils par classe (courbes précision/rappel) et de généraliser l'évaluation par validation croisée plutôt que par un unique split.

- Suivre les performances dans le temps : historiser les métriques à chaque réentraînement hebdomadaire pour détecter toute dérive du modèle ou du vocabulaire des tweets.